

12 금융 취약계층을 위한 사용자 맞춤형 계약 문서 단순화 및 위험 안내 에이전트

소속 정보컴퓨터공학부

분과 A

팀명 하프피프티

참여학생 김민찬, 전동훈, 최민제

지도교수 최동희

과제 개요

01 계약 위험, 사람도 LLM도 놓친다

정부·법인 직접 판정 조항 기준·본 과제 실측

일반 대중 위험 판정 정답률 (N=33)

61%

상위 LLM 단일 호출 정확도 (Fable 5)

59%

등급 LLM 단일 호출 정확도 (Haiku 4.5)

52%

본 과제 파이프라인 (Haiku 4.5)

70%

03 실제 피해 규모

4만 936건

전세사기 피해자 누적 결정

국토교통부·2026.8 기준

9조 4,189억 원

HUG 전세보증 대위변제 5년 누적·회수율 24%

2020~2024, 4만 3,631건

5만 7,359건

상반기 금융민원·보험 민원 49%

금융감독원·2025 상반기

02 계약 위험은 언제 발견되는가

골든셋은 분쟁 이후의 판정문으로 구성

① 주택금융연구·2025

전세보증 45.3만 건 분석, 부채비율 90% 초과 시 사고 승산 29.9배

② 금융분쟁조정위·2017-17/2018-8

즉시연금 약관의 불명확한 이자·사업비 조건, 분쟁 후에야 위험 확정

③ 한국공정거래조정원·2025-03

광고대행 위탁계약의 과도한 위약금 조항, 분쟁조정으로 판정

④ 약관규제법 위반 유형 10종

책임 면제·과도한 위약금·일방적 해지·불명확한 수수료...

→ 위험 발견 시점을 서명 이후의 분쟁에서 서명 이전의 질문으로

● 과제 선정 배경


- 전세사기·금융상품 불완전판매·위임 계약 약용 등 계약 문서를 정확히 이해하지 못해 생기는 피해가 해마다 늘고 있으며, 전세사기 피해자 결정만 누적 4만 건을 넘어섰음
- 대출·보험·임대차 계약은 조항이 길고 전문용어가 많아 고령층·외국인·사회초년생 등 금융 취약계층은 불리한 조항을 스스로 알아채기 어렵고, 위험은 대부분 분쟁이 생긴 뒤에야 "늦은 기록"으로 발견됨
- 범용 LLM은 문서 이해력이 높아졌지만 계약 해석에 그대로 쓰면 ① 호출마다 달라지는 판단 ② 누구에게나 같은 난이도의 설명 ③ 무엇을 더 확인해야 하는지 알려주지 않는 행동 지침 부재 ④ 없는 조항·법령을 인용하는 환각의 네 가지 한계가 남음
- 이 한계는 더 큰 모델로 해소되지 않아 상위 모델의 단일 호출도 정부·법인 판정 조항 27건에서 정확도 0.59에 그쳤으므로, LLM 출력을 절차적으로 분해하고 단계별 품질을 측정·검증하는 체계가 필요
- 대상 사용자:** 고령층·외국인·사회초년생 등 금융 취약계층
- 대상 문서:** 임대차 계약서·대출·보험·카드 등 금융 약관

● 과제 목표

- 계약서 각 조항마다 쉬운 설명·위험 여부/유형·위험 근거·확인 질문의 4종 출력을 제공하는 설명 중심 계약 해석 에이전트를 개발하고, 텍스트·PDF·사진 입력을 받는 실제 웹 서비스로 배포
- 일반 성인·고령층·외국인(16개 언어) 페르소나에 맞춰 설명 난이도와 언어만 조정하고 위험 판정은 동일하게 유지해, 누가 봐도 같은 위험을 각자의 눈높이로 이해하도록 함
- 역할 분리형 5단계 파이프라인(Parser → Domain → Analysis → Persona → Judge)으로 판정의 일관성과 근거 충실성을 확보하고, 근거 인용을 원문과 대조해 환각을 차단
- 정부·법인 판정 기반 골든데이터셋 211행, 3회 반복 다수결, 4모델 Judge 교차검증, 일반 대중 사람 평가를 "믿을 수 있는 답"인지 다중 검증
- 확인 질문·협상 문구·상담기관 연결로 탐지에서 행동까지 잇는 서명 전 점검 도구를 제공해 위험 발견 시점을 서명 이전으로 앞당김

기술 설명

● 시스템 아키텍처 · 5단계 파이프라인



① [Parser · 규칙 기반 조항 분리]

- "제N조"가 줄 시작에 올 때만 새 조항으로 분리하고, 문장 중간에 조 참조나 "제6조의3" 형태는 조항 시작으로 보지 않음
- 별자·별표·부칙은 버리지 않고 별도 규칙으로 보존하며, 양식 빈칸 조항은 원장 문장 판별로 걸러 조항 오인을 방지
- LLM을 호출하지 않는 결정적 전처리로 입력 손실을 차단하고, 조항 커버리지 70% 미만이면 경고 표시

② [Domain · 문서 유형 판별]

- 주택/상가 임대차·보험·대출·카드 등 13종 유형을 문서 전체에서 1회 판별해 모든 조항 분석에 공유 상태로 주입
- 같은 "2기 연체 시 해지" 문언도 주택임대차는 안전, 상가임대차는 법정 기준이 3기라 위험으로 판정이 갈림
- 유형 정보를 "표준적 조항"이라는 관대 신호로 오용하던 회귀를 2x2 어블레이션으로 규명하고 재설계에 정식 반영

③ [Analysis · 4종 출력 + 인용 대조]

- 위험/주의/안전 3단계와 약관규제법 대응 위험 유형 10종으로 판정하고 쉬운 설명·근거·확인 질문을 한 번에 생성
- 예: 수리비 전가 조항 → 위험·책임 면제, 근거 "민법 제623조 임대인 수선 의무 배제", 질문 "큰 수리 비용은 누가 내나요?"
- 근거 인용이 원문에 실재하는지 코드로 대조해 창작 인용은 제시도하고, 소진 시 '주의'로 강등해 사용자 확인 요구

④ [Persona · 맞춤 제작성 · 다국어]


- 판정은 그대로 두고 설명만 일반·성인·고령층·외국인(16개 언어) 눈높이로 제작하므로 위험 판정이 바뀌지 않음
- 고령층 모드는 24개 조항 실측에서 문장 길이 -31%, 전문용어 -52%를 보였고 위험 판정은 24/24 조항에서 동일
- 근거 인용·절차단말기 호환 텍스트, 조항별 협상 문구와 상담기관 연결로 탐지에서 행동까지 이어줌

⑤ [Judge · 재검 · 품질 게이트]

- 별도 재검 모델(Sonnet)이 Clarity·Faithfulness·Risk Coverage·Actionability 4축을 문서 단위로 5점 척도로 측정
- 평균 3.5 또는 Faithfulness 3.0 미만이면 충실성·위험식별 미달은 Analysis, 이해용이성 미달은 Persona로 최대 2회 재실행
- 채점자 자체를 Claude·Solar·DeepSeek·Gemini 4모델로 교차검증해 정답 뎡커 40행 기준 97~100% 일치 확인

⑥ [전처리 · 보안 · 외부 API]

- 주민등록번호·카드·계좌·전화·이메일 5종을 LLM 호출 전 규칙 마스크, 계약 본문과 파일명은 로그에 남기지 않음
- 정규화·규칙 탐지·격리·난수 구분자 격리의 다중 인젝션 방어로 적대적 공격 125건에서 화면 권동 0건
- Upstage Document Parse(OCR)·Gemini(STT) 연동, 계정 보관은 클라이언트 측 PBKDF2+AES-GCM 암호화로 서버가 복호화 불가



연구 결과 및 기대효과

리콜 1.00

A등급 위험 조항 10건 미탐지 0건

위험 오탐 0건

정상 표준계약서 94개 조항

0.52 → 0.70

동일 Haiku, 파이프라인 적용 시 정확도

57.8%

고령층 맞춤 설명 선호 · 일반 대중 33명

71.4%

시스템-정답 일치 · 일반인 61.0%

● 검증 결과 요약

검증 항목	결과
공식 Test 40건	정확도 72.5% · Precision 0.71 / Recall 0.91 / F1 0.80
A등급 27건	리콜 1.00 · 위험 미탐지 0건 · 정확도 0.70
금융 전이 16건	정확도 0.75 · 리콜 1.00
정상 표준계약서 5문서 94조항	'위험' 오탐 0건 · 주의 9건
LLM Judge 교차검증	Clarity · Risk Coverage · Actionability 100%, Faithfulness 97%
적대적 벤치마크 125건	사용자 화면 기준 공격 성공률 0.0%
페르소나 적용 24조항	판정 불변 24/24 · 문장 길이 -31% · 전문용어 -52%
공정위 실측 1,046건 커버리지	위험 유형 탐지율 66%

● 기대효과

- 서명 전에 조항별 위험을 인지하고, 확인 질문·협상 문구·상담기관 연결로 바로 행동할 수 있는 금융 취약계층의 사전 점검 도구
- 정부·법인 판정 골든셋 + 반복 다수결 + 4모델 교차검증 + 사람 평가의 다중 검증으로 "그럴듯한 답"이 아닌 "믿을 수 있는 답"을 제공
- 고령층 모드 · 16개 언어 · TTS · 점자 텍스트로 금융소비자보호법의 설명의무 이행과 고령자 보호 절차를 보조

● A등급 27건 혼동행렬

	예측 위험/주의	예측 안전
실제 위험 10건	10	0
실제 안전 17건	8	9

위험 10건은 하나도 놓치지 않았고, 오답 8건은 전부 안전을 주의로 부른 과잉 경보이며, 위험을 놓치는 방향보다 피해가 적아 의도적으로 허용. 4모델 Judge 교차검증 정답률 97~100%, 금융 전이 리콜 1.00

● 골든데이터셋 구성

세트	행	출처 · 검수
공식 Test	44	hldcc 조정제 · LBox 판례 · AI Hub
임대차 확정	34	조항예-판례, 경제 안전 사례 포함
금융 전이	32	금감원 분쟁조정 결정제
스프린트 확충	101	법제처 OPEN API 수집 + 독립 제3자 검증
합계	211	A등급 193 / C등급 18 · 위험 119 / 안전 91

● 향후 연구

- 표준약관 · 판정레그 RAG 도입으로 조항 텍스트 밖의 범위 보완
- 실거과가 · 등기부 등 계약서 밖 위험 신호 통합, 외국인 페르소나 언어별 정량 검증
- 전문가 · 고령층 평가자 확대로 사람 평가 표준 확장, 신탁 도메인 보강



GitHub

서비스 채팅

